Análise de preços de carros

Análise exploratória em SQL de 2.500 carros

AUTOR
Charliton Nogueira

DATA
Outubro de 2026

FERRAMENTA
SQL (SQLite)

FONTE
Kaggle (zafarali27)

Principais achados

Nenhuma das variáveis disponíveis está associada ao preço. As correlações do preço com ano, quilometragem e motor ficam entre −0,04 e 0,00, e o teste t não encontrou diferença de preço entre carros novos, seminovos e usados. Os preços seguem uma distribuição uniforme entre 5 mil e 100 mil.

Os testes de consistência encontraram registros impossíveis, como 525 carros novos com mais de 100 mil de quilometragem e Teslas movidos a diesel. Os dados parecem ter sido gerados aleatoriamente, o que impede usá-los para estudar preços de veículos.

Contexto e preparação dos dados

A tabela `car_price_prediction` tem 2.500 carros e 10 colunas: marca, modelo, ano de fabricação (2000 a 2023), tamanho do motor, combustível, câmbio, quilometragem, condição (novo, seminovo ou usado) e preço. Não há valores ausentes nem identificadores repetidos. A fonte não informa a origem dos dados nem a moeda, e os preços aparecem aqui sem símbolo de moeda.

As primeiras consultas mostraram resultados pouco plausíveis para um mercado de veículos. Por isso, além das onze perguntas propostas, incluí testes de consistência dos registros.

1. Distribuição dos preços

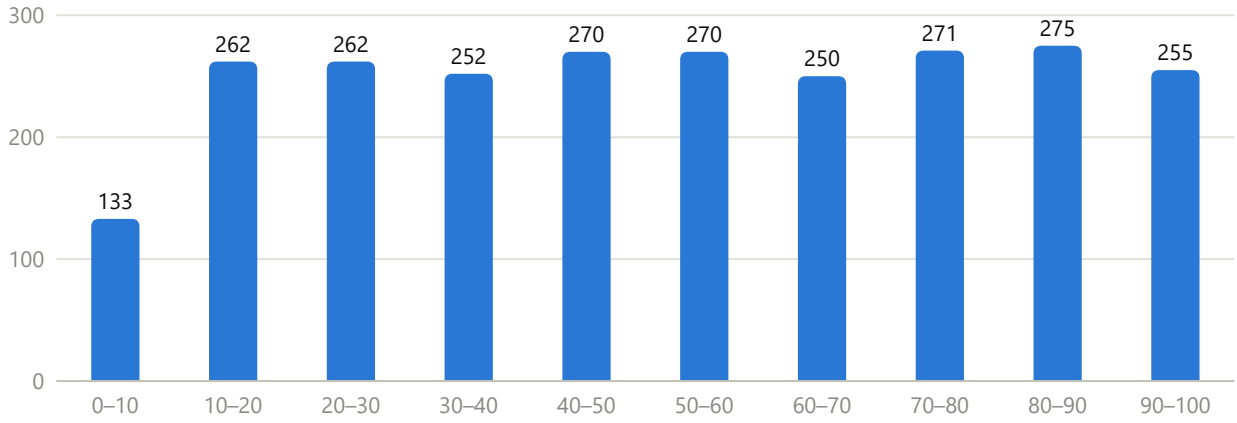
PERGUNTAS 1 E 2

Tabela 1. Estatísticas do preço (2.500 carros)

Média	Mediana	Desvio padrão	Mínimo	1º quartil	3º quartil	Máximo
52.638	53.485	27.296	5.011	28.812	75.831	99.983

Valores na moeda original do dataset, que não é informada pela fonte.

Figura 1. **Carros por faixa de preço (em milhares)**



A primeira faixa é menor porque o preço mínimo da base é de cerca de 5 mil.

> Cada faixa de 10 mil reúne cerca de 10% dos carros, e média e mediana ficam próximas. Preços de veículos costumam se concentrar nas faixas mais baratas, com poucos carros caros. A distribuição observada é uniforme. Para conferir, comparei o desvio padrão com o de uma distribuição uniforme entre 5 mil e 100 mil, que é de 27.424; o observado é 27.296. Os quartis estão igualmente espaçados e não há outliers.

2. Combustível, condição e marca

PERGUNTAS 3, 4, 8 E 9

Tabela 2. **Quantidade de carros e preço médio por combustível, condição e marca**

Variável	Categoria	Carros	Preço médio
Combustível	Diesel	655	54.997
Combustível	Gasolina	630	51.768
Combustível	Elétrico	614	51.103
Combustível	Híbrido	601	52.547
Condição	Usado	855	52.471
Condição	Seminovo	836	53.519
Condição	Novo	809	51.905
Marca	Toyota	374	52.079
Marca	Audi	368	51.953
Marca	BMW	358	54.157
Marca	Mercedes	353	53.191
Marca	Honda	352	52.050
Marca	Tesla	348	53.476
Marca	Ford	347	51.593

> Cada combustível tem de 24% a 26% dos carros, cada condição de 32% a 34% e cada uma das sete marcas cerca de 14%. A maior diferença de preço médio entre categorias é de 4 mil. A BMW, marca de preço

médio mais alto, fica 5% acima da Ford, a de preço mais baixo. As contagens por ano e por combinação de condição, combustível e câmbio são igualmente equilibradas: cada uma das 24 combinações tem de 3% a 5% dos carros.

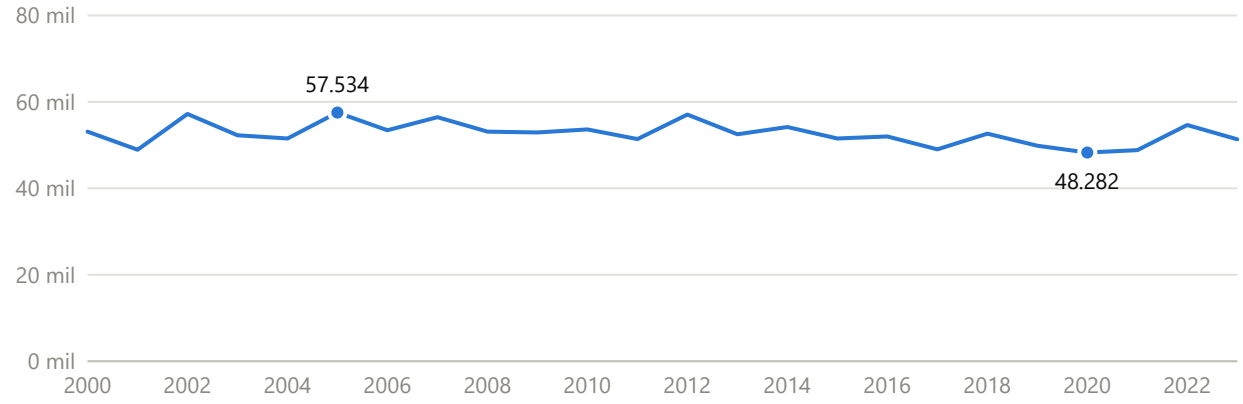
3. Ano, quilometragem e motor

PERGUNTAS 5 E 10

Tabela 3. Correlação das variáveis numéricas com o preço

Variável	Pearson com o preço
Ano de fabricação	-0,04
Quilometragem	-0,01
Tamanho do motor	0,00

Figura 2. Preço médio por ano de fabricação



Eixo a partir de zero, para não exagerar oscilações pequenas. Os pontos marcam o maior e o menor valor.

As três correlações ficam perto de zero, e o preço médio por ano oscila sem tendência. Em dados reais, seria esperado que carros mais antigos e mais rodados custassem menos. O tamanho médio do motor fica entre 3,2 e 3,7 litros em todos os anos. Separado por condição, o preço médio anual varia de 39 mil a 64 mil sem padrão definido, e em vários anos o preço médio dos usados supera o dos novos.

4. Preço por condição do carro

PERGUNTAS 6, 7 E 11

Tabela 4. Preço e quilometragem por condição

Condição	Carros	Preço médio	Quilometragem média
Seminovo	836	53.519	151.986
Usado	855	52.471	148.587
Novo	809	51.905	148.668

Tabela 5. **Teste t de Welch para o preço médio entre condições**

Condição A	Condição B	Estatística t	Resultado (5%)
Seminovo	Novo	1,19	Sem diferença significativa
Seminovo	Usado	0,79	Sem diferença significativa
Novo	Usado	-0,43	Sem diferença significativa

> O maior preço médio é o dos seminovos e o menor, o dos novos. O teste t de Welch, aplicado aos três pares de condições, não passa de 1,96 em nenhum caso, então as diferenças não são significativas. A quilometragem média é de cerca de 150 mil nas três condições, inclusive entre os carros novos.

5. Testes de consistência

VERIFICAÇÃO COMPLEMENTAR

Para testar a hipótese de dados gerados aleatoriamente, consultei combinações que não deveriam aparecer num cadastro real de veículos.

Tabela 6. **Testes de consistência dos registros**

Verificação	Resultado
Quilometragem média dos carros novos	148.668
Carros novos com mais de 100 mil de quilometragem	525
Carros elétricos com motor a combustão informado	614
Teslas não elétricos (diesel, gasolina ou híbrido), de 348	248
Carros elétricos com câmbio manual	323

> Dos 809 carros novos, 525 têm mais de 100 mil de quilometragem. Todos os elétricos têm motor de 1 a 6 litros informado, e 71% dos Teslas estão cadastrados como diesel, gasolina ou híbridos, embora a marca só fabrique elétricos. Os valores de cada coluna parecem ter sido sorteados de forma independente, o que é coerente com a ausência de relação entre as variáveis.

Conclusão

As perguntas propostas assumem que ano, quilometragem, marca e condição influenciam o preço. Nesta base, nenhuma dessas variáveis mostrou relação com o preço: as correlações são próximas de zero, as médias por categoria são parecidas e o teste de hipóteses não encontrou diferença entre condições.

O preço uniforme, o equilíbrio entre categorias e os registros impossíveis indicam dados gerados aleatoriamente. Um modelo preditivo treinado nesta base não teria desempenho melhor que usar o preço médio. Para estudar o mercado de veículos, seria necessário usar dados reais de anúncios ou de tabelas de referência.

Limitações

- A origem dos dados e a moeda dos preços não são informadas pela fonte.
- A conclusão de que os dados são sintéticos é uma inferência baseada nos padrões e nos testes de consistência.

- O SQLite não calcula p-valores; o teste t foi avaliado pelo limite de 1,96, válido para grupos deste tamanho.

Reprodução

As consultas de todas as perguntas estão em `car_price.sql` e rodam sobre `car-price.db` em qualquer cliente SQLite. O banco é gerado por `gerar_banco.py` a partir do arquivo `car_price_prediction_.csv`, disponível no Kaggle.