Preços de carros: quando os dados não sustentam a análise

Análise exploratória em SQL de 2.500 carros

AUTOR
Charliton Nogueira

DATA
Outubro de 2026

FERRAMENTA
SQL (SQLite)

FONTE
Kaggle (zafarali27)

Principais achados

Nenhuma característica disponível explica o preço dos carros. Ano, quilometragem e motor têm correlação próxima de zero com o preço, e carros novos não são mais caros que usados. O preço segue uma distribuição uniforme, algo que não acontece em mercados reais.

Os testes de consistência mostram registros impossíveis, como carros novos com mais de 100 mil de quilometragem e Teslas a diesel. A conclusão é que a base foi gerada aleatoriamente e não serve para estudar o mercado de veículos nem para treinar um modelo de preço.

Contexto e preparação dos dados

A tabela `car_price_prediction` tem 2.500 carros e 10 colunas: marca, modelo, ano de fabricação (2000 a 2023), tamanho do motor, combustível, câmbio, quilometragem, condição (novo, seminovo ou usado) e preço. Não há valores ausentes nem identificadores repetidos. A fonte não informa a origem dos dados nem a moeda; por isso, os preços aparecem sem símbolo de moeda.

O objetivo era responder às onze perguntas propostas sobre o que influencia o preço. Logo nas primeiras consultas, os resultados se mostraram estranhos para um mercado de veículos. Por isso, além das perguntas, incluí testes de consistência para verificar se os registros fazem sentido.

1. O preço tem distribuição uniforme

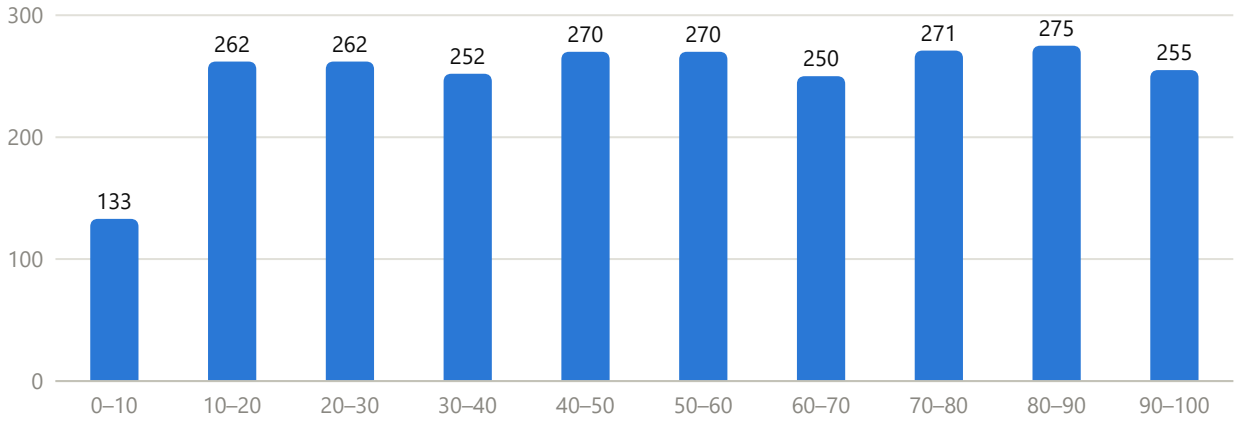
PERGUNTAS 1 E 2

Tabela 1. Estatísticas do preço (2.500 carros)

Média	Mediana	Desvio padrão	Mínimo	1º quartil	3º quartil	Máximo
52.638	53.485	27.296	5.011	28.812	75.831	99.983

Valores na moeda original do dataset, que não é informada pela fonte.

Figura 1. **Carros por faixa de preço (em milhares)**



A primeira faixa é menor porque o preço mínimo da base é de cerca de 5 mil.

> Preços de veículos costumam se concentrar nas faixas mais baratas, com uma cauda de carros caros. Aqui, cada faixa de 10 mil reúne cerca de 10% dos carros, do início ao fim da escala, e média e mediana são quase iguais. É o desenho de uma distribuição uniforme. O teste é direto: o desvio padrão teórico de uma distribuição uniforme entre 5 mil e 100 mil é de 27.424, praticamente igual ao observado. Os quartis igualmente espaçados e a ausência de outliers confirmam a leitura.

2. Todas as categorias têm o mesmo tamanho e o mesmo preço

PERGUNTAS 3, 4, 8 E 9

Tabela 2. **Quantidade de carros e preço médio por combustível, condição e marca**

Variável	Categoria	Carros	Preço médio
Combustível	Diesel	655	54.997
Combustível	Gasolina	630	51.768
Combustível	Elétrico	614	51.103
Combustível	Híbrido	601	52.547
Condição	Usado	855	52.471
Condição	Seminovo	836	53.519
Condição	Novo	809	51.905
Marca	Toyota	374	52.079
Marca	Audi	368	51.953
Marca	BMW	358	54.157
Marca	Mercedes	353	53.191
Marca	Honda	352	52.050
Marca	Tesla	348	53.476
Marca	Ford	347	51.593

> Cada combustível responde por 24% a 26% dos carros, cada condição por 32% a 34% e cada uma das sete marcas por cerca de 14%. O preço médio também quase não muda: a maior diferença entre categorias é de 4 mil, numa escala que vai de 5 mil a 100 mil. A BMW, marca mais cara da base, custa em média apenas 5% mais que a Ford, a mais barata. O mesmo equilíbrio aparece ano a ano e no cruzamento entre condição, combustível e câmbio, em que cada uma das 24 combinações reúne de 3% a 5% dos carros.

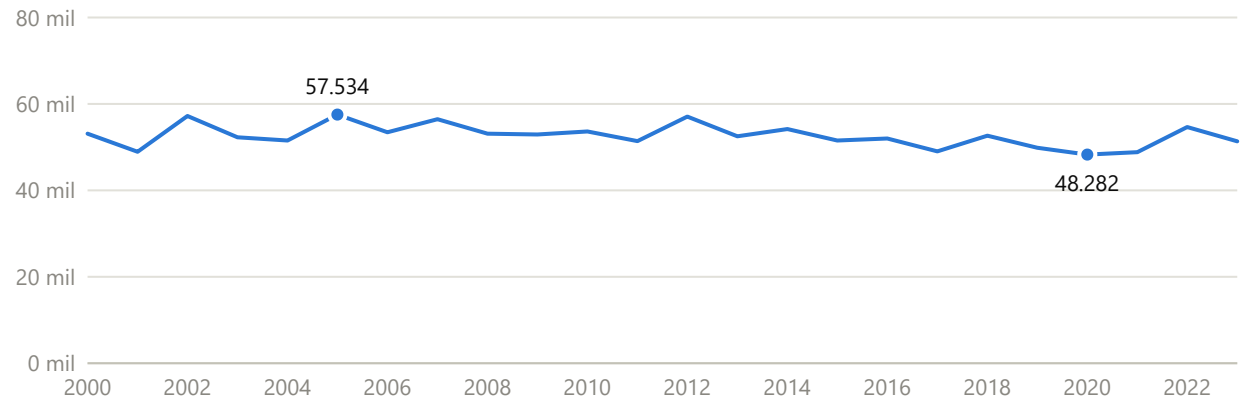
3. Ano, quilometragem e motor não afetam o preço

PERGUNTAS 5 E 10

Tabela 3. **Correlação das variáveis numéricas com o preço**

Variável	Pearson com o preço
Ano de fabricação	-0,04
Quilometragem	-0,01
Tamanho do motor	0,00

Figura 2. **Preço médio por ano de fabricação**



Eixo a partir de zero, para não exagerar oscilações pequenas. Os pontos marcam o maior e o menor valor.

> Num mercado real, carros mais antigos e mais rodados valem menos. Aqui, as três correlações são praticamente zero, e o preço médio por ano oscila sem tendência. O tamanho médio do motor também não muda com o tempo, ficando entre 3,2 e 3,7 litros em todos os anos. Separado por condição, o preço médio anual varia de 39 mil a 64 mil sem padrão, e em vários anos os usados aparecem mais caros que os novos.

4. A condição do carro não muda o preço

PERGUNTAS 6, 7 E 11

Tabela 4. **Preço e quilometragem por condição**

Condição	Carros	Preço médio	Quilometragem média
Seminovo	836	53.519	151.986
Usado	855	52.471	148.587
Novo	809	51.905	148.668

Tabela 5. **Teste t de Welch para o preço médio entre condições**

Condição A	Condição B	Estatística t	Resultado (5%)
Seminovo	Novo	1,19	Sem diferença significativa
Seminovo	Usado	0,79	Sem diferença significativa
Novo	Usado	-0,43	Sem diferença significativa

> Os seminovos têm o maior preço médio e os novos, o menor. Para saber se essas diferenças são reais, apliquei o teste t de Welch aos três pares de condições. Em nenhum deles a estatística passa de 1,96, então não há evidência de diferença de preço entre novos, seminovos e usados. A quilometragem média também é a mesma nas três condições, cerca de 150 mil, inclusive entre os carros novos.

---

5. Os registros não são consistentes

VERIFICAÇÃO COMPLEMENTAR

Os resultados anteriores levantaram a hipótese de que os dados foram gerados aleatoriamente. Para testá-la, consultei combinações que não deveriam existir num cadastro real de veículos.

Tabela 6. **Testes de consistência dos registros**

Verificação	Resultado
Quilometragem média dos carros novos	148.668
Carros novos com mais de 100 mil de quilometragem	525
Carros elétricos com motor a combustão informado	614
Teslas não elétricos (diesel, gasolina ou híbrido), de 348	248
Carros elétricos com câmbio manual	323

> Quase dois terços dos carros novos têm mais de 100 mil de quilometragem, todos os elétricos têm tamanho de motor entre 1 e 6 litros, e 71% dos Teslas aparecem como movidos a diesel, gasolina ou híbridos, embora a marca só fabrique elétricos. Cada coluna parece ter sido sorteada de forma independente das demais, o que explica por que nenhuma relação aparece nas análises anteriores.

Conclusão

As perguntas propostas partem da premissa de que ano, quilometragem, marca e condição influenciam o preço. A análise mostra que, nesta base, nenhuma delas influencia: as correlações são nulas, as médias por categoria são iguais e o teste de hipóteses não encontra diferença entre condições.

A explicação está na própria base. O preço uniforme, o equilíbrio perfeito entre categorias e os registros impossíveis indicam que os valores foram gerados aleatoriamente, coluna por coluna. Um modelo de preço treinado nestes dados erraria tanto quanto uma estimativa pelo preço médio.

Esse é um resultado útil. Antes de investir em modelagem, a primeira etapa é verificar se os dados carregam o sinal que se quer modelar. Para estudar o mercado de veículos, o caminho é substituir esta base por dados reais de anúncios ou de tabelas de referência de preços.

Limitações

- A origem dos dados e a moeda dos preços não são informadas pela fonte.
- A conclusão de que os dados são sintéticos é uma inferência a partir dos padrões e dos testes de consistência, não uma informação da fonte.
- O SQLite não calcula p-valores; o teste t foi avaliado pelo limite de 1,96, válido para grupos deste tamanho.

Reprodução

As consultas de todas as perguntas estão em `car_price.sql` e rodam sobre `car-price.db` em qualquer cliente SQLite. O banco é gerado por `gerar_banco.py` a partir do arquivo `car_price_prediction_.csv`, disponível no Kaggle.